PROYECTO FINAL · IA GENERATIVA

Analytica

Asistente experto en Google Analytics 4 con Gemini, RAG y agentes en LangGraph

Este documento explica qué hace el asistente, cómo está construido, por qué se tomó cada decisión técnica y qué resultados obtuvo.

Gemini | ChromaDB | LangGraph | Memoria conversacional

José A. Espinosa · Máster en Data Science · Evolve España

Noviembre 2026

1 · EL PROBLEMA

La documentación de GA4 está dispersa y cambia a menudo

Quien trabaja en marketing digital necesita respuestas rápidas y fiables sobre cómo medir en GA4, y hoy tiene que buscarlas entre decenas de artículos.

Dispersa

Eventos, parámetros, canales y atribución viven en artículos distintos del Centro de Ayuda y de la guía para desarrolladores.

Cambiante

La terminología evoluciona: por ejemplo, las «conversiones» pasaron a llamarse «eventos clave».

Riesgo de error

Un chatbot genérico puede inventar nombres de eventos o rutas de menú que parecen reales pero no existen.

Objetivo: un asistente que responda solo con la documentación oficial, cite la fuente y recuerde el contexto de la conversación.

2 · STACK TECNOLÓGICO

Componentes de la solución

Todo el stack es el que exige el enunciado. Gemini aporta la «inteligencia» (entender y redactar) y la representación numérica de los textos; ChromaDB guarda esos vectores para buscarlos por significado; LangGraph orquesta los pasos y la memoria.

CAPA	TECNOLOGÍA	PAPEL EN EL PROYECTO
LLM	Google Gemini Flash	Reformula preguntas y genera las respuestas. El modelo se elige automáticamente entre los disponibles para la API key.
Embeddings	Gemini Embeddings	`gemini-embedding-001`, con cambio automático a `gemini-embedding-2` si se agota la cuota.
Base vectorial	ChromaDB	Colección persistente con distancia coseno.
Agente	LangGraph + LangChain	Grafo de 3 nodos con estado y checkpointer para la memoria.
Entorno	Google Colab / Jupyter	Notebook con todo el pipeline y la demo documentada.
Interfaz (bonus)	Streamlit	Chat web que reutiliza el mismo código de `src/`.

3 · BASE DE CONOCIMIENTO

16 artículos oficiales de GA4, en español

Temas: fundamentos e ID de medición · eventos y parámetros · dimensiones personalizadas · DebugView · canales · atribución · comercio electrónico.

Descarga
Centro de Ayuda + guías para desarrolladores, con caché local

→

Limpieza
BeautifulSoup elimina menús, scripts y textos de interfaz

→

Chunking
1.000 caracteres y 150 de solapamiento, respetando párrafos

→

Embeddings
Gemini, por lotes y con reintentos

→

ChromaDB
Colección persistente (coseno)

16
documentos oficiales

225
fragmentos indexados

>20
páginas de texto (mínimo exigido)

¿Por qué limpiar el HTML? Los menús y textos como «¿Te ha resultado útil?» se repiten en todas las páginas. Si se indexaran, contaminarían los embeddings y la búsqueda devolvería ruido.

¿Por qué 1.000 caracteres con 150 de solapamiento? Es el tamaño de 1-2 párrafos: suficiente para una idea completa (un evento y sus parámetros) sin mezclar temas. El solapamiento evita perder información en los cortes.

Verificación antes de conectar el agente

Consultas directas a ChromaDB: en todas, el primer resultado es el documento correcto. Cuanto menor es la distancia coseno, más parecidos son la pregunta y el fragmento.

CONSULTA DE PRUEBA	PRIMER DOCUMENTO RECUPERADO	DISTANCIA
¿Qué eventos se recogen con la medición mejorada?	Eventos de medición mejorada	0.220
¿Se puede editar el grupo de canales predeterminado?	Grupo de canales predeterminado	0.234
¿Qué parámetros lleva el evento purchase?	Referencia de eventos recomendados	0.160
¿Cómo depuro eventos en tiempo real?	Guía para desarrolladores: enviar eventos (DebugView)	0.243

> Resultados obtenidos en la ejecución del notebook con `gemini-embedding-001`.

4 · AGENTE EN LANGGRAPH

Tres nodos que se ejecutan en cada pregunta

Pregunta
del usuario

→

`contextualize`
Si hay historial, Gemini reescribe la pregunta para que se entienda sola

→

`retrieve`
Busca en ChromaDB los 5 fragmentos más útiles con MMR

→

`generate`
Gemini responde con el system prompt, el contexto y el historial

→

Respuesta
con fuentes citadas

¿Por qué un flujo fijo?

El enunciado pide que el agente use la base de conocimiento **en cada consulta**. Con un flujo fijo, la recuperación nunca se salta y cada respuesta queda anclada a la documentación.

¿Por qué MMR?

Maximal Marginal Relevance elige fragmentos relevantes pero distintos entre sí. Así se evita pasar al LLM cinco fragmentos casi iguales del mismo artículo.

5 · MEMORIA + RAG

La memoria también mejora la búsqueda

Una pregunta de seguimiento no sirve para buscar en una base vectorial: «¿y cómo la activo?» no dice de qué se habla. El nodo `contextualize` la convierte en una pregunta completa antes de recuperar.

TURNO ANTERIOR

¿Qué eventos recoge la medición mejorada?

PREGUNTA DE SEGUIMIENTO

¿Y cómo la activo o desactivo?

LO QUE BUSCA EL RETRIEVER (EJEMPLO)

¿Cómo se activan o desactivan los eventos de medición mejorada en GA4?

Sin reformular

Buscar con «¿y cómo la activo?» puede traer fragmentos poco relevantes, y la respuesta empeora aunque el LLM tenga el historial.

Reformulando

El retriever encuentra el artículo de medición mejorada y el agente responde con los pasos de Administración correctos.

5 · MEMORIA DE CONVERSACIÓN

Checkpointer de LangGraph por `thread_id`

Cómo funciona

- `InMemorySaver` guarda el estado completo tras cada paso: mensajes, pregunta reformulada y contexto.
- Cada conversación tiene su `thread_id`: el agente recupera su historial automáticamente.
- El LLM ve los 10 mensajes más recientes, para controlar coste y longitud.

Cómo se demuestra en el notebook

- **Pregunta 3:** «¿Y cómo la activo?» depende de la pregunta 2.
- **Pregunta 6:** pide resumir lo hablado al inicio de la conversación.
- **Hilo nuevo:** «¿Cuál fue mi primera pregunta?» → no lo sabe, porque cada hilo está aislado.

> En Streamlit, cada sesión del navegador tiene su propio `thread_id`, y el botón «Nueva conversación» crea otro.

6 · INGENIERÍA DE PROMPTS

System prompt: decisiones y justificación

El system prompt son las instrucciones fijas que recibe Gemini en cada respuesta. Define quién es el asistente, cómo debe responder y qué no debe hacer. El texto completo está en el README.

DECISIÓN	MOTIVO
Rol «Analytica», consultor GA4 para equipos de marketing	Fija el dominio, el nivel técnico y un tono coherente entre turnos.
Responder **solo** con el contexto recuperado	Principal defensa contra alucinaciones de eventos, parámetros o rutas de menú.
Frase explícita cuando no hay información	Mejor admitir el límite y sugerir otra búsqueda que inventar.
Citar fuentes con su título	Trazabilidad: el usuario puede verificar en la documentación oficial.
Respuesta directa, luego pasos numerados, ~250 palabras	Formato práctico para alguien que está configurando GA4.
Rechazo amable fuera de GA4; sin asesoría legal	Delimita el alcance (la pregunta 7 lo demuestra).

7 · RETOS Y DECISIONES TÉCNICAS

Lo que se resolvió durante el desarrollo

Cuota gratuita de embeddings

El plan gratuito limita las peticiones diarias. **Solución:** se reutiliza el índice si ya existe y, si se agota la cuota, se cambia automáticamente de modelo. Cada modelo tiene su propia colección.

Modelos que cambian

Los nombres de modelos de Gemini se retiran con el tiempo. **Solución:** el código consulta los modelos disponibles para la API key y elige el Flash más reciente.

Errores temporales de la API

Errores 429, 500 y 503 puntuales. **Solución:** reintentos con espera creciente en los embeddings y en el LLM.

Seguridad de la API key

Nunca está en el código: se lee de Colab Secrets, de `.env` o de los secrets de Streamlit. `.env` y `chroma_db/` están en `.gitignore`.

8 · PRUEBAS DOCUMENTADAS

Las 7 preguntas de ejemplo del notebook

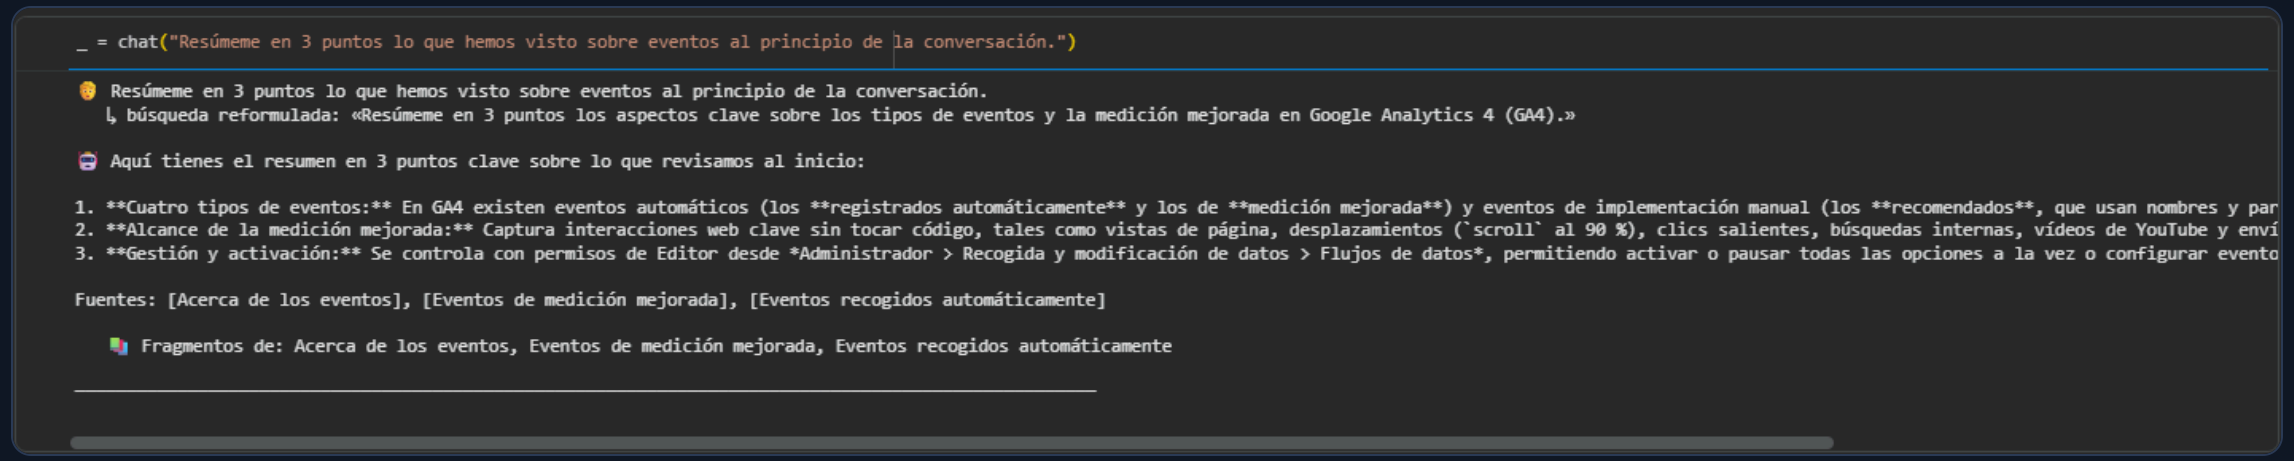
Se ejecutan en una misma conversación para que cada una pueda apoyarse en las anteriores. Cada pregunta comprueba una capacidad distinta del agente.

#	PREGUNTA	QUÉ DEMUESTRA
1	¿Qué tipos de eventos existen en GA4 y en qué se diferencian?	RAG básico y fuentes citadas
2	¿Qué eventos recoge la medición mejorada?	Recuperación precisa
3	¿Y cómo la activo o desactivo?	**Memoria** + búsqueda reformulada
4	¿Qué parámetros necesita el evento purchase?	Documentación técnica de e-commerce
5	¿Puedo editar el grupo de canales predeterminado?	Responde con alternativas
6	Resúmeme lo que vimos sobre eventos al principio	**Memoria** de varios turnos
7	¿Me recomiendas una receta de paella?	Límites del dominio

8 · RESULTADOS REALES

La memoria funciona entre turnos

PREGUNTA 6: «RESÚMEME EN 3 PUNTOS LO QUE HEMOS VISTO SOBRE EVENTOS AL PRINCIPIO DE LA CONVERSACIÓN»



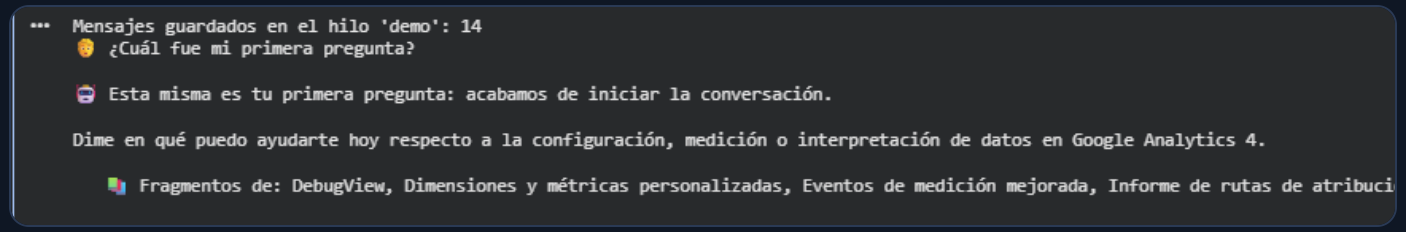
✓ **Reformulación:** «al principio de la conversación» se convierte en una búsqueda concreta sobre tipos de eventos y medición mejorada.

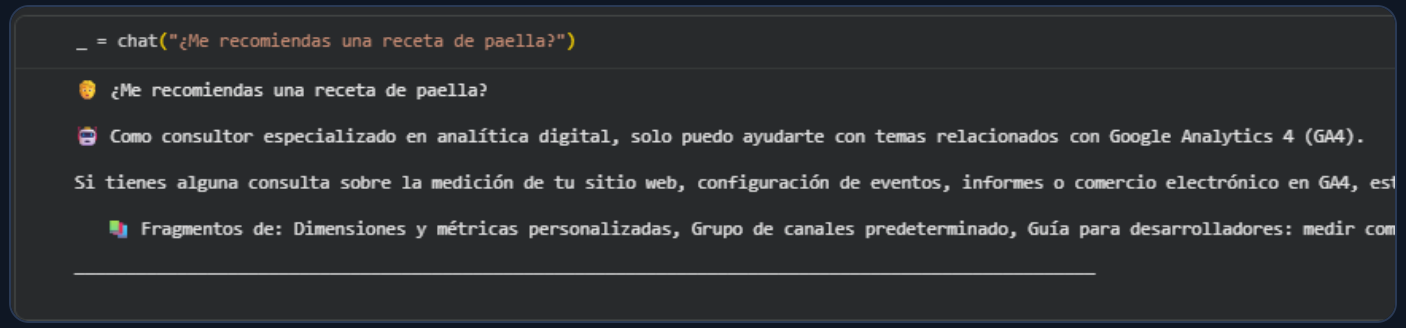
✓ **Coherencia:** el resumen recoge lo que se respondió en las preguntas 1 a 3: tipos de eventos, medición mejorada y cómo activarla.

✓ **Trazabilidad:** cita las fuentes, que coinciden con los fragmentos recuperados de ChromaDB.

8 · RESULTADOS REALES

Hilos aislados y límites del dominio





✓ **El hilo «demo» guarda 14 mensajes** (7 preguntas y 7 respuestas).

✓ **En un hilo nuevo**, el agente no sabe cuál fue la primera pregunta: la memoria está separada por `thread_id`, como debe ser.

✓ **Fuera de dominio:** rechaza la receta de paella y redirige a GA4, como indica el system prompt.

A mejorar: aun así consulta ChromaDB. Un nodo *router* podría saltarse la búsqueda en estas preguntas.

9 · CÓMO PROBARLO

Ejecutar el proyecto en 3 pasos

No hace falta instalar nada: el notebook funciona en Google Colab y descarga el código y las dependencias por sí mismo.

1 · API key

Crear una clave gratuita de Gemini en Google AI Studio y guardarla en Colab, en el icono de la llave (Secrets), con el nombre `GOOGLE_API_KEY`.

2 · Abrir el notebook

Abrir `notebooks/asistente_ga4_rag.ipynb` desde el repositorio en Colab (Archivo → Abrir cuaderno → GitHub).

3 · Ejecutar todo

Entorno de ejecución → Ejecutar todo. La última celda abre un chat para hacer preguntas propias; se sale escribiendo `salir`.

> También se puede abrir como aplicación web con `streamlit run app/streamlit_app.py`. Las instrucciones para ejecutarlo en local están en el README.

10 · CONCLUSIONES

Resultados y próximos pasos

Lo conseguido

- Base vectorial con 16 documentos oficiales y 225 fragmentos.
- Recuperación precisa, verificada antes de conectar el agente.
- Agente LangGraph con memoria comprobada: reformula, resume y aísla hilos.
- Prompt documentado: cita fuentes y reconoce sus límites.
- Código modular, README completo e interfaz Streamlit.

Mejoras posibles

- Re-ranking de los fragmentos recuperados.
- Búsqueda híbrida (BM25 + vectores) para nombres exactos de eventos.
- Evaluación automática con un conjunto de preguntas de referencia.
- Actualización periódica de la documentación indexada.
- Nodo *router* para no consultar ChromaDB en preguntas fuera de dominio.
- Memoria persistente (SQLite) entre sesiones.

Repositorio: **github.com/joseaespinosa02/asistente-ga4-rag**